

Rapport de TP : Le Teacher Forcing par le Code

Tâche 1 : Spécifier le chemin du jeu de données et lancer la démonstration.

```
dataset_path = r"C:\Users\Hiba\Desktop\S9\belcaid\TP_LLM_TALN\teacher forcing\ManaGPT-1020_4080_prompts_and_generated_texts.csv"
```

```
demonstrate_teacher_forcing_from_csv(dataset_path)
```

Tâche 2 : Charger le fichier CSV dans un DataFrame pandas

```
df = pd.read_csv(file_path)
```

Tâche 3 : Identifier la colonne contenant le texte généré à utiliser.

```
column_name_to_use = 'generated_response'
```

Tâche 4 : Pour une meilleure lisibilité, filtrer le dataset pour ne garder que les phrases courtes (moins de 15 mots).

```
df['word_count'] = df[column_name_to_use].str.split().str.len()
short_sentences_df = df[df['word_count'] < 15]
```

Tâche 5 : Sélectionner une seule phrase d'exemple au hasard parmi les phrases courtes.

```
example_text = short_sentences_df.sample(n=1)[column_name_to_use].iloc[0]
```

Tâche 6 : Préparer la phrase en la découpant en "tokens" et en ajoutant les marqueurs de début et de fin.

```
tokens = ["<start>"] + example_text.split() + ["<end>"]
```

Tâche 7 : Créer la séquence d'INPUT (ce que le modèle reçoit) en retirant le dernier token.

```
input_sequence = tokens[:-1]
```

Tâche 8 : Créer la séquence TARGET (ce que le modèle doit prédire) en retirant le premier token

```
target_sequence = tokens[1:]
```